# Система анализа метаинформации музейного фотоисточника

Горлова Ксения Георгиевна
ОП МЦМГН-211, «Цифровые методы в гуманитарных науках»
НИУ ВШЭ

Научный руководитель - Ефимова Ирина Владимировна, доцент, кандидат филологических наук, Генеральный директор (global CEO) компании Semantic Hub

# Потребности практической работы с фотографиями в музеях

- Интеграция коллекций
- Доступ к информации
- Улучшение поиска (низкая пертинентность поисковой выдачи)
- Сохранность
- Взаимосвязь текстовых данных и предметов
- Отсутствие применимых стандартов метаданных

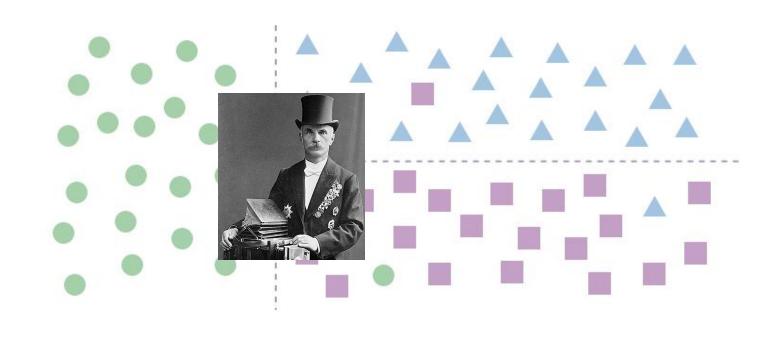
# Специфика фотоисточника в музее

- Массовость как предмета хранения
- Тиражируемость и копийность
- Общий предмет для архивов/музеев/библиотек
- Взаимосвязь с гравюрой, живописью, кинодокументами, письменными и вещественными источниками
- Для интерпретации требуется подробное описание
- Уязвимость к условиям хранения
- Малая изученность

# Объект

# Предмет





Принимая концепцию, что поиск по изображениям может быть таким же доступным, как в данный момент поиск по тексту, цель работы — это разработка системы анализа, хранения и представления метаинформации о фотоисточнике в метаданных.

# Соотношение метаинформации и метаданных. Задачи

*Метаинформация* — вся совокупность

информации об информационном

объекте (имеющаяся и потенциальная)

Метаданные — структурированные

определенным образом данные о данных

#### 1. Обзор и анализ:

- предметной области,
- цифровых проектов, включающих фотоисточники,
- цифровых методов анализа изображений
- стандартов метаданных
- методик описания музейного предмета
- 2. Построение системы анализа метаинформации фотоисточника в метаданных
- 3. Эксперимент по проверке теоретического базиса

# Цифровые проекты

#### Цели создания:

Исследование корпуса

Тематическое моделирование данных и кластеризация

Анализ данных

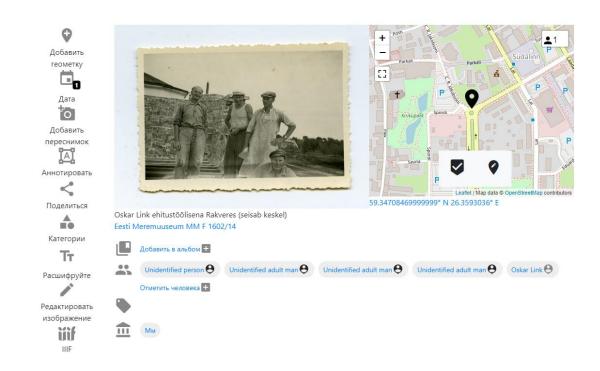
Музейная коммуникация

Превентивное копирование оригиналов

Аккумуляция и публикация информации

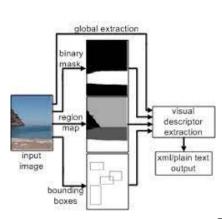
### Задачи атрибуции

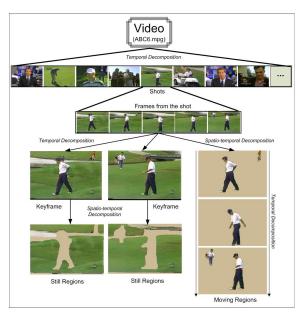
### Ajapaik

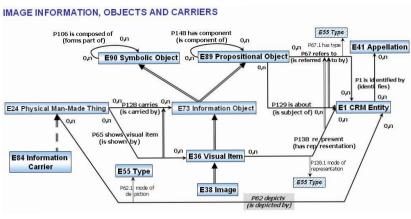


#### СТАНДАРТЫ МЕТАДАННЫХ

- Dublin Core
- PhotoRDF
- MPEG-7
- Exif
- ||||
- VRA
- CIDOC-CRM
- CDWA
- AAF
- NISO Z39.87

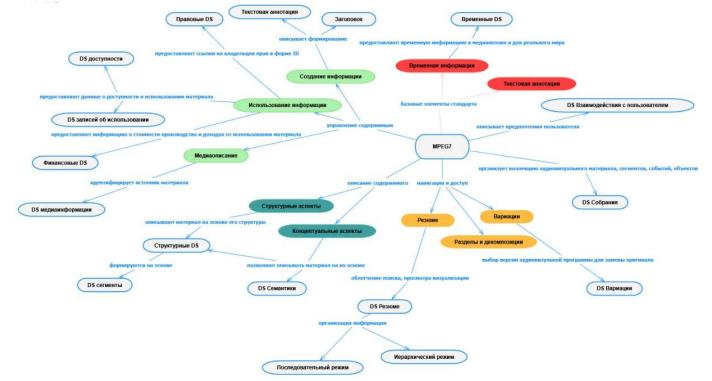






CIDOC-CRM. E38 Image

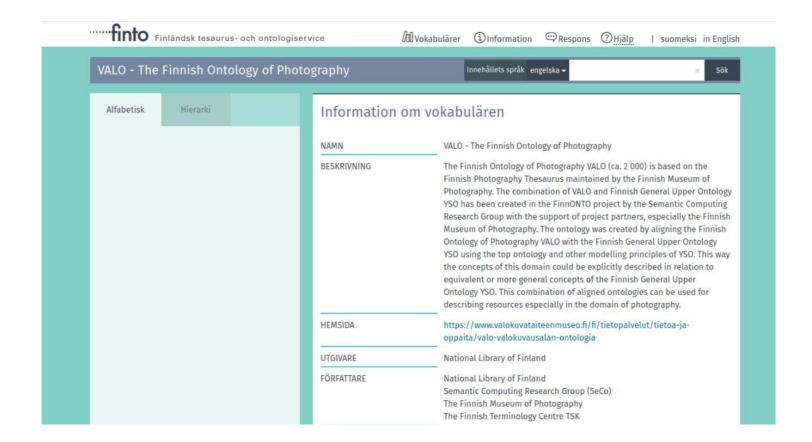
#### Regions supported for descriptor extraction.



#### **ТЕЗАУРУСЫ**

- FinnONTO
- AAT Getty
- AAT Taiwan
- ICONCLASS

- Недостатки:
- 1) FinnONTO не рассчитан на задачи информационного поиска
- 2) Тематически близкие тезаурусы разработаны за рубежом, прямое применение не учитывает специфику музейного дела в России и соотношение понятий с терминами русского языка
- 3) Являются более общими, разработаны для категорий «искусство и архитектура»
- 4) Не включают семантику сюжетов изображений (кроме ICONCLASS, однако он рассчитан в большей степени на предметы живописи), не задействована информация внутри непосредственно изображения







А.М. Горький и М.Ф. Андреева в летней мастерской И.Е. Репина на даче «Пенаты»

Изобразительная Техническая

 Размер:
 33,1x26,2 (паспарту); 22,4x15,7 (фотография)

 Место создания:
 СССР

 Номер в Госкаталоге:
 41241312

 Номер по КП (ГИК):
 ГЛМ КП 44021

 Номер по кт (тик):
 17/10/18/11/4402

 Инвентарный номер:
 Ф-22322

Внешняя ссылка:

Булла Карл Карлович

Период создания:

Материал, техника

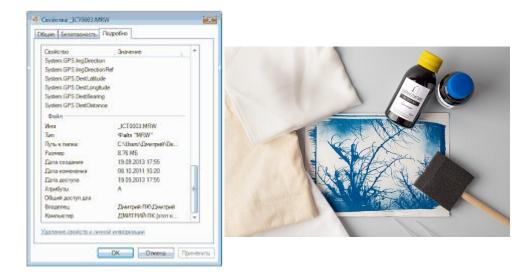
Местонахождение

Федеральное государственное бюджетное учреждение культуры "Государственный музей истории российской литературы имени В.И. Даля"

фотобумага, картон, фотопечать

В интерьере летней мастерской. Во время работы художника над портретом Андреевой. Горюкий (слева) в рост. 348 параво, в темной косоворотке, в темных брюках, заправленных в сапоги, сидит на подоконнике нога на ногу. М. Ф. Андреева в рост, коруге 34 аплею, ата съемки: лето 1905. На обороте графитовым карандашом рукой ст.н. с. ТІМ Елены Елизаровны Миропольской: А.М. Горький и И.М.Ф. Андреева в / мастерской художника / И.Е. Репина / Пенаты Куоккала / штамп позднейший. В верхием правом углу графитовым карандашом: Приобретено по счету / Булла 14.03.1928. / Ленинград, На обороте поздний штамп: Фотография / Президума / Ленинград, На обороте поздний штамп: Фотография / Президума / Ленинград, На обороте поздний штамп: Фотография / Президума / Ленинград, На обороте поздний штамп: Фотография / Президума / Ленинград, Убскопомом / работы / Бр. Булла / Пр. 25 Октября 54 / Телефон 3-64-46

Текстовая Технотронная



```
Lister - [G:\XP_Sergey\D.bin]
файл Правка Вид Справка
000001F0: 02 04 03 01 0A 08 12 09|0E 05 0B 07 13 06 0F 00
00000200: 01 36 00 00 01 74 00 00|01 36 00 00 01 74 00 00 |
```

# Методика. JSON и JSON-

Потребность создания унифицированной системы поиска и анализа фотоисточников с учетом имеющихся проблем

# Была выбрана **фреймовая семантико-ориентированная структура метаданных**

Рекомендванный формат JSON-LD

- Расширяем, позволяет встраивать в себя существующие онтологические модели, человеко- и машиночитаем
- Гибок и использует подход Linked Data
- . Легко интегрируется с современными цифровыми инструментами
- JSON уже используется в представлении метаданных системы Госкаталога

#### . Основа для построения схемы:

- Методические рекомендации по описанию фотоисточников в музее.
- Формат представления данных JSON в Госкаталоге.
- . Онтологической модели CIDOC-CRM
- Отдельные разделы стандарта MPEG-7 (для мультимедийных объектов), относящихся к статичному изображению.
- . Стандарты метаданных для объектов культурного наследия
- . Собственный анализ фотоисточников с точки зрения работы в музее.

#### Министерство культуры Российской Федерации

Федеральное государственное бюджетное учреждение культуры «Государственный центральный музей современной истории России»



#### АТРИБУЦИЯ ФОТОИСТОЧНИКОВ В МУЗЕЕ

МЕТОДИЧЕСКИЕ РЕКОМЕНДАЦИИ



Москва 2022

# Структура системы

## Составляющие системы

- 1. Сопроводительные метаданные
- 2. Метаданные изображения

### Примеры семантических

### категорий изображения

- 1. Пространство (интерьер и экстерьер)
- 2. Сущность
- 1. Символический объект (текст, символ)
- 2. Персона
- 3. Предмет
- 4. Строение
- 5. Объект живого мира
- 6. Паттерн

• • •

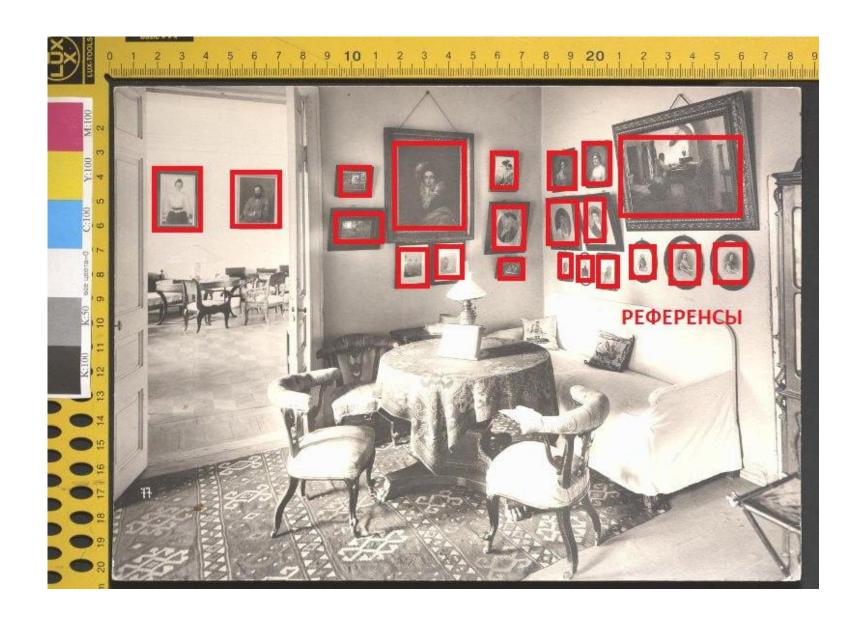
3. Референс == изображение (внутри изображения)

```
/home/ksuloko/vkr_text/main_data_structure.js - Mousepad
                                                                                         "@context": "@value",
Файл Правка Поиск Вид Документ Справка
                                                                                         "photosource_metadata":
        //МЕТАДАННЫЕ ИЗОБРАЖЕНИЯ
   "imgData":
        {"type": "object",
        "title": "Метаданные изображения",
                                                                                                    "@type": "our_context:type:id",
        "value": Object,
        "properties": {
             "frontSideData": {"type": "array",
                                                                                             "data":
                "title": "Метаданные изображения лицевой стороны",
                 "value": Array,
                                                                                                    "inner_id":
                "items": {
                      "area": {"type": "object",
                                                                                                        "пате": "Внутренний идентификатор",
                         "title": "Пространство",
                                                                                                        "@type": "our_context:type:E42",
                          "value": Object,
                                                                                                        //"@type": "https://www.cidoc-crm.org/Entity/e42-identifier/version-6.2"
                          "properties": {
                                                                                                        "@value": "123456"
                              "id": { "type": "number",
                                  "title": "Идентификатор",
                                                                                                    "name":"NAME",
                                  "value": Number
                                                                                                    "creation_place": "place_of_creation",
                                                                                                    "find_place": "place_of_find",
                               "URI": {"type": "string",
                                                                                                    "description": "description of thing",
                                  "title": "URI",
                                                                                                    "num_of_parts":"1",
                                  "value": String
                                                                                                    "reg_number_gk": "reg_number_gk",
                                                                                                    "inv_number": "inv_number",
                              "idPlace": {"type": "object",
                                  "title": "Идентификатор места",
                                                                                                    "museum"
                                  "value": Object,
                                  "properties": {
                                       "geoLabels": {"type": "array",
                                                                                                        "museum_id":
                                           "title": "Геометки",
                                           "value": Array,
                                                                                                            "@type": "our_context:type:id",
                                           "items": {
                                                                                                            "@value": "12345"
                                                "type": "string",
                                               "title": "Геометка",
                                                                                                        "name": "name of museum",
                                               "value": String
                                                                                                        "inn":"12345",
                                                                                                        "kopuk": "12345"
```





Автор: Георгий Пинхасов. Фотоагенство Magnum.



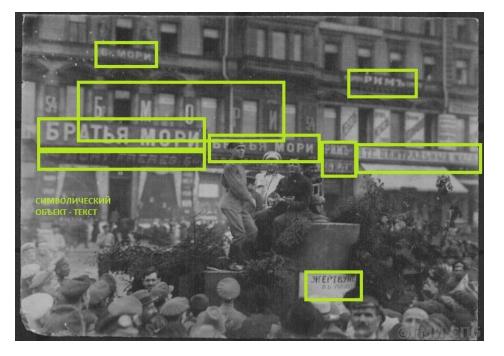
Фотография Карла Буллы (Госкаталог РФ)



Автор: Георгий Пинхасов. Фотоагенство Magnum



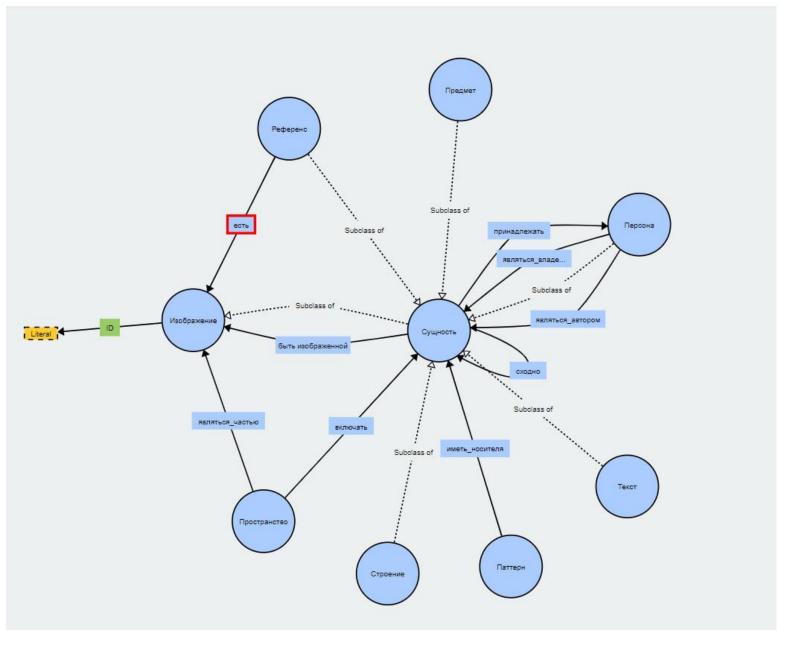
Фотографии Карла Буллы на ресурсе Ајараік



Фотография Карла Буллы (Госкаталог РФ)

Семантический граф отдельных категорий метаинформации музейного фотоисточника, отражающий структуру отношений при поиске по изобразительному компоненту

Форматы: JSON-LD RDF-Turtle SVG



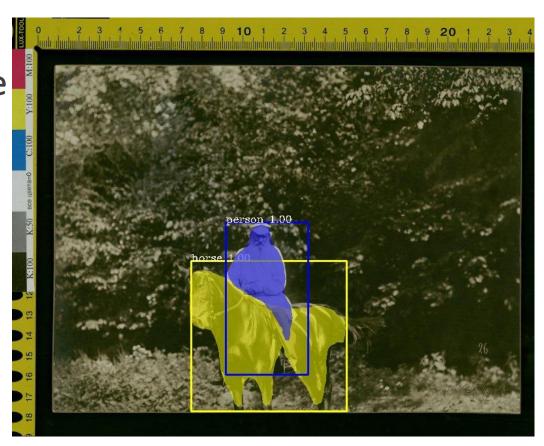
Для построения использовалось приложение WebWOWL

# Экспериментальная часть

Можно ли корректно извлечь метаданные имеющимися инструментами?

Семантическая сегментация

Сопоставление лиц — верификация сходства



Карл Булла. Фотография из Госкаталога РФ

#### ВЫБОРКА

Фотографии, принадлежащие авторству фотоателье Карка Буллы
После частки данных от ошибочных вкемений и вичета скилок, то которым фотографии не доступны, общее количество фотографий составило:
1186 stongered
Boxes.
1776 изображений
Ma seec
32 — амерая и оборотная горона
вимает:
20 creprionap
7 омимов текстовки источников
Разрешние
Or 1800 * 284 gp 4448 * 59584 nunccetels

Поиск в Госкаталоге по объектам данных: Фильтры Тип музейного предмета - «Фотографии и негативы» «Название» «Описание» «Автор» Регулярное выражение <r'(^|\s)Булл'>

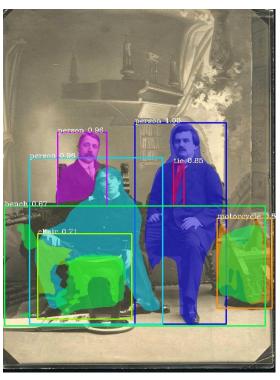
Python Pandas

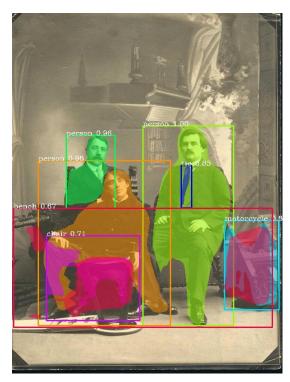
## Библиотеки и модели

- Python Pixellib
- Семантическая сегментация
- модели Deeplabv3 + на данных Pascal VOC
- модели Xception, натренированная на данных ADE\_20K
- Сущностная сегментация
- модели Mask R-CNN на данных COCO
- Python DeepFace
- OpenCV

### РЕЗУЛЬТАТЫ СЕМАНТИЧЕСКОЙ и СУЩНОСТНОЙ СЕГМЕНТАЦИИ









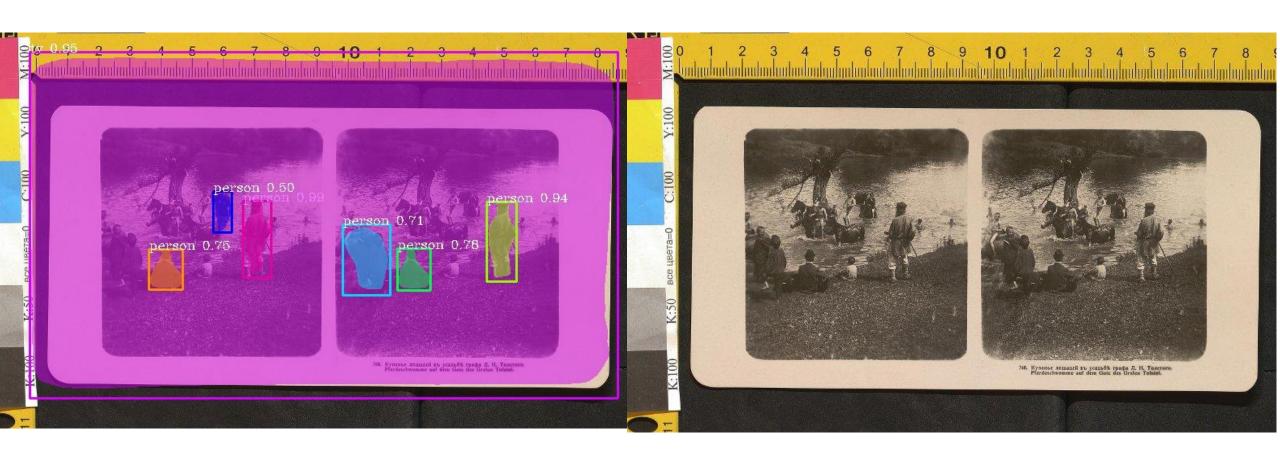
Deeplabv3 pascalvoc

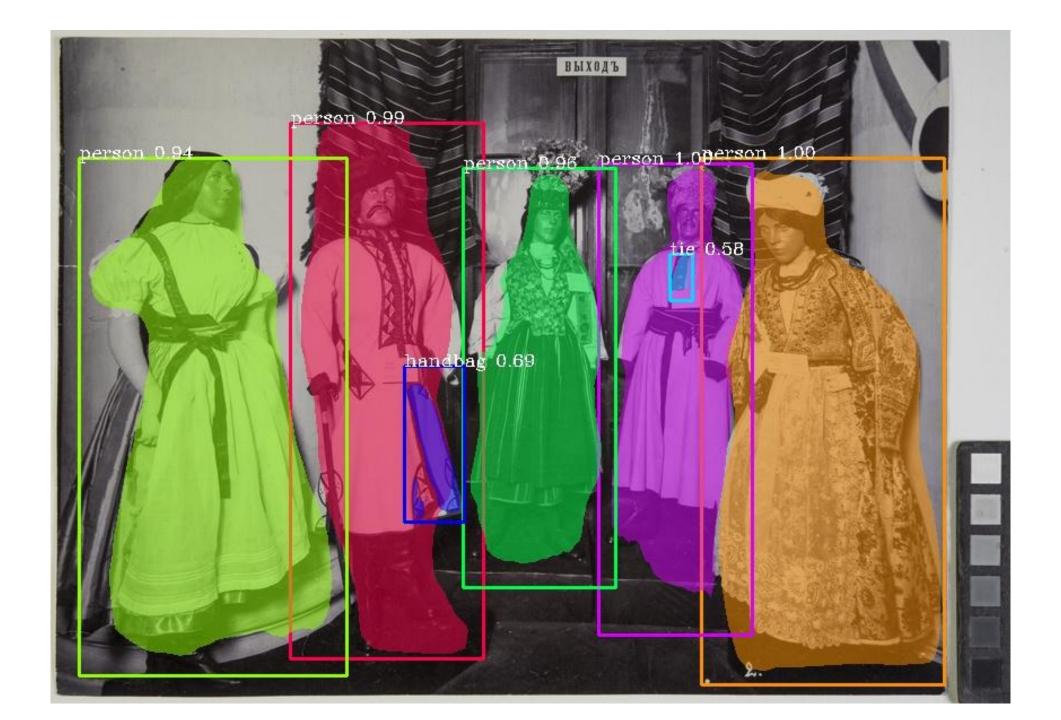
mrcnnaverage

mrcnn

Xception - age20k

#### СЛОЖНЫЕ СЛУЧАИ

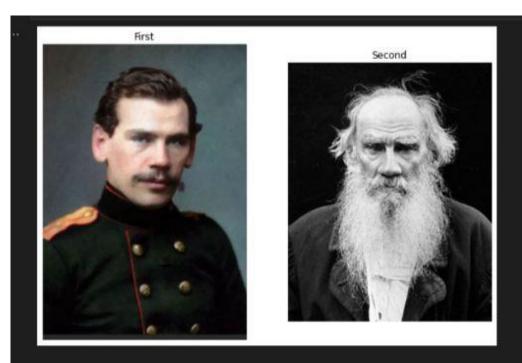








#### ВЕРИФИКАЦИЯ ЛИЦ



{'verified': True, 'distance': 0.47441720158282896, 'threshold': 0.6, 'model': 'VGG-Face', 'detector\_backend': 'retinaface', 'similarity\_metric': 'euclidean', 'facial\_areas': {'img1': {'x': 88, 'y': 69, 'w': 108, 'h': 149}, 'img2': {'x': 189, 'y': 123, 'w': 230, 'h': 340}}, 'time': 2.47}
Это один и тот же человек

#### РЕКОМЕНДАЦИИ и ВЫВОДЫ

- Стандартизация способов съемки, качества съемки, формата файлов, цветового пространства файлов
- Создание профильных размеченных наборов данных
- Обучение моделей на собственных размеченных наборах данных под узкие задачи



Изображение фотографических источников из фондов МБУК "Городской музей". Г. Саров.

#### НОВИЗНА И ПРАКТИЧЕСКАЯ ЗНАЧИМОСТЬ

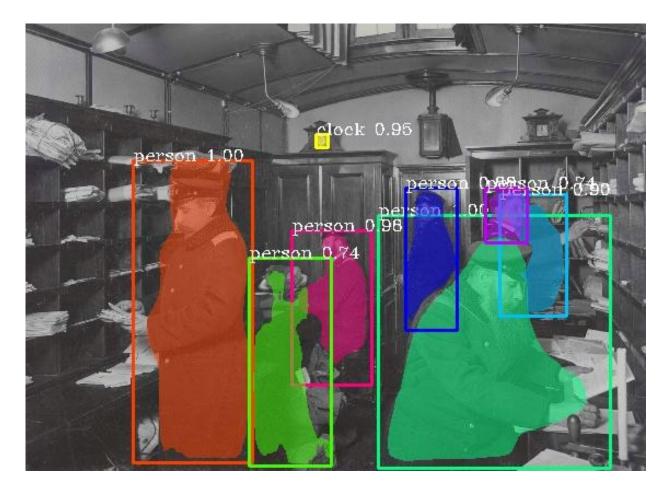
- Разработана схема структурированных данных для новой предметной области цифрового музейного фотоисточника, основанная на существующих стандартах. Схема предусматривает применение технологии связанных данных (Linked Data), выражена в форме семантического ориентированного графа и предназначена для решения исследовательских задач в музее. Итоговая структура метаданных учитывает специфику музейного фотоисточника в цифровом виде и задачи поиска информации по изображениям.
- Экспериментальная часть показывает возможность корректного извлечения метаданных при дальнейшей доработке методики, существующих цифровых инструментов и наборов данных.

«Следующий шаг — атрибуция и распознавание объектов на изображениях. Например, у меня есть гравюра: на ней 20 персон и десятки элементов — медали, шпаги, элементы интерьера и т.п.. Система, возможно, увидит людей на уровне «обнаружена персона», но не детализации, например, стиля костюма, временного периода, типа шпаги, значения медали и т.п. К сожалению, сегодняшние системы не могут искать, сопоставлять и анализировать подобные детали. Для этого множество специалистов по всему миру должны в начале заниматься их обучением на различных примерах. Эти специалисты должны точно понимать, ради чего они это делают и какие выгоды это принесет им в будущем.»

Владимир Определёнов, бывший заместитель директора по цифровому развитию ГМИИ им. Пушкина

Источник: «Системный Блокъ»

### • СПАСИБО ЗА ВНИМАНИЕ!



GitHub: <a href="https://github.com/Kseniya-Loko/vkr\_code">https://github.com/Kseniya-Loko/vkr\_code</a>